Comparação de imagens por similaridade[1]

Descrição

O programa utiliza redes neurais convolucionais e cálculos de similaridade (otimizados para execução em GPU) para comparar dois grupos de imagens com base no conteúdo.

A implementação foi realizada em Python 3, com bibliotecas Keras e Tensorflow, dentre outras.

Casos de Uso

1) O principal caso de uso nas perícias de informática ocorre quando o perito recebe um CD com arquivos que precisam ser pesquisados em um HD examinado. A abordagem tradicional é a de pesquisa por identicidade (Hashs) ou pesquisa manual/visual.

2) Em um exame de HD relacionado a uma investigação de falsificação de moeda, é possível colocar diversas imagens de cédulas em um diretório e comparar com imagens de um HD questionado.

3) Em um exame de HD relacionado a uma investigação de falsificação de documentos, é possível colocar diversas imagens de documentos de segurança em um diretório e comparar com imagens de um HD questionado.

Objetivo

O objetivo do projeto é fazer a comparação automatizada com base nas características visuais da imagem, extraídas através de uma rede convolucional pre-treinada (arquitetura VGG-16[2] - mas pode ser alterada para qualquer outra).

Os passos para instalar e executar o programa são descritos a seguir.

1. Instalar o docker para CPU

Instruções para instalação do docker para CPU em https://docs.docker.com/docker-for-windows/ ou https://www.docker.com/docker-ubuntu.

Se desejar utilizar uma GPU (sugiro, **no mínimo**, usar uma **GTX 1050 Ti** e, **preferencialmente**, uma **GTX 1080 Ti**), a versão do docker deve ser para GPU - consulte o passo 10.

2. Obter imagem.

Comando:
docker pull ufoym/deepo:all-jupyter-py36-cpu

1 Esse projeto de busca de imagens por similaridade foi efetuado como atividade de pesquisa individual e não foi desenvolvido sob supervisão ou qualquer tipo de vínculo institucional.

2 Simonyan, K. and Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. arXiv preprint arXiv:1409.1556.2.

3. Iniciar container

Comando para iniciar ativando o notebook:

sudo docker run -it -p 8888:8888 -v **/home/jm:/home_docker** **ufoym/deepo:all-jupyter-py36-cpu** jupyter notebook --no-browser --ip=0.0.0.0 --allow-root --NotebookApp.token= --notebook-dir='**/home_docker**/report_similaridade'

O docker inicia no diretório '/home_docker/report_similaridade'.

O arquivo runcpu.sh contem esse comando. Sugiro alterar lá para ficar mais fácil (ou criar um arquivo .bat).

Observação:
"/home/jm" pode ser substituído por qualquer diretório existente da sua máquina - não precisa necessariamente ser seu "home", basta que seja qualquer diretorio e que você coloque a pasta report-similaridade nele.
Quando o docker iniciar, esse diretório pode ser acessado como /home_docker
os diretorios dos arquivos questionado e padrao têm que ser acessiveis a partir do diretorio report_similaridade.

4. Abrir página do jupyter

Abrir um navegador e digitar: http://0.0.0.0:8888

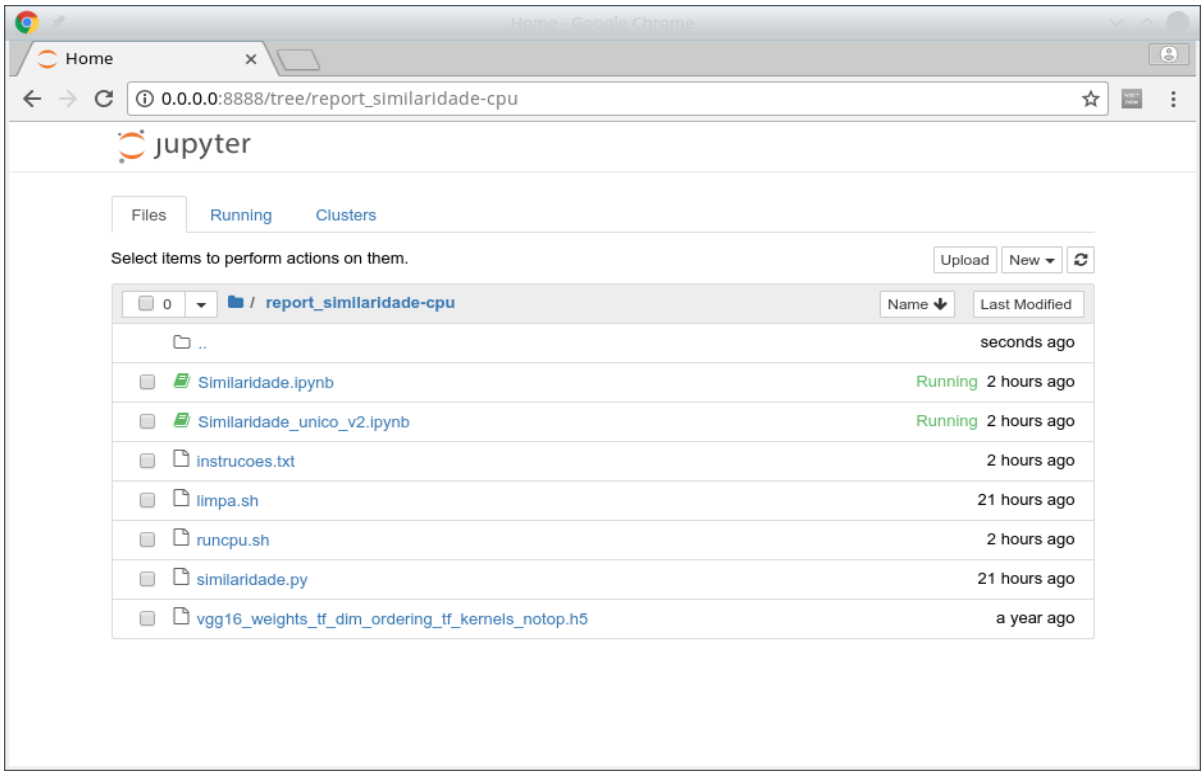

5. Selecionar um notebook

Existem 2 notebooks: Similaridade_unico_v2.ipynb e notebooks Similaridade.ipynb

Sugiro que inicie o **Similaridade_unico_v2.ipynb**

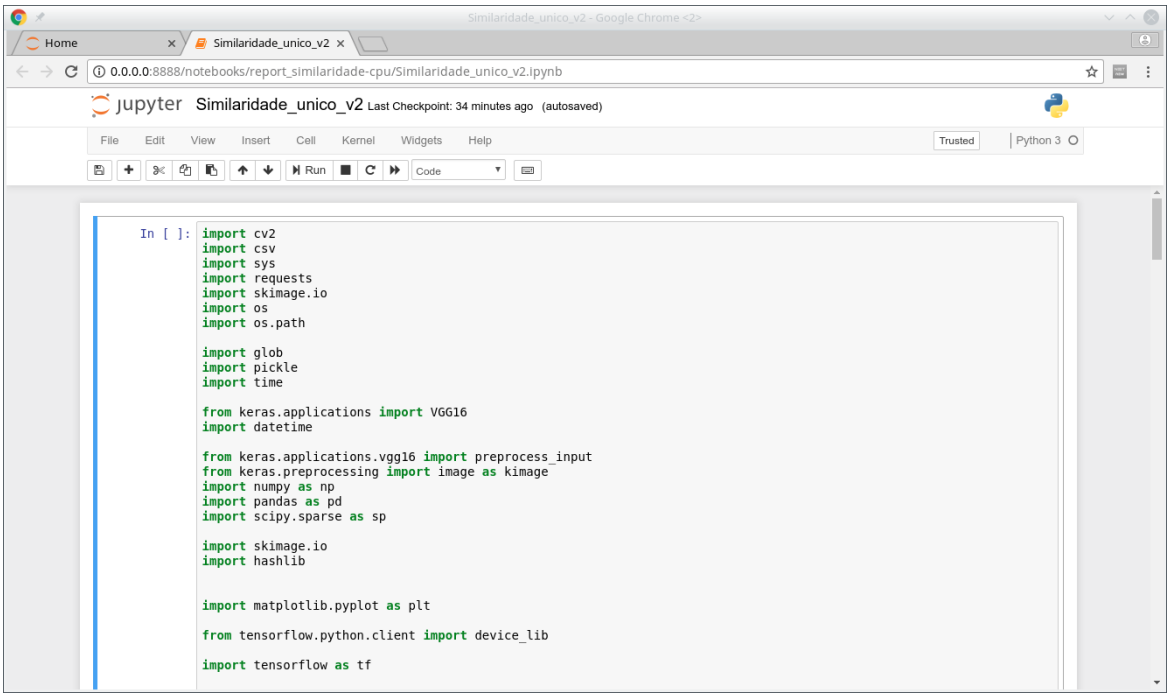

Esse notebook contém apenas uma célula com as partes principais do código para geração dos relatórios (o resto foi colocado no arquivo similaridade.py para simplificar).
O outro notebook (Similaridade.ipynb) tem várias células com todo o código. A funcionalidade é idêntica, mas permite uma execução passo a passo (útil para depurar ou ver as etapas do trabalho).

6. Ajustar caminho dos arquivos e "nome de exibição" dos conjuntos de dados

Ajuste os quatro valores a seguir:

arqs["busca"]["raiz"] = "./img_busca/"
arqs["busca"]["nome_exibicao"] = "CD Anexo"

arqs["material"]["raiz"] = "./img_quest/"
arqs["material"]["nome_exibicao"] = "HD Examinado"

7. Ajuste de parâmetros de busca e geração de relatórios

Por fim, você também pode alterar os parametros das buscas por similaridade dos relatorios gerados:

gera_html_busca(dados, arqs, excl, N=3, minimoinicial=0.20, minimofinal=0.15)
gera_html_material(dados, arqs, excl, N=3, minimoinicial=0.20, minimofinal=0.15)

N=3 - para cada arquivo analisado (no CD, por exemplo), reporta até 3 semelhantes (no HD), de acordo com os índices de similaridade minimoinicial e minimofinal.

minimoinicial=0.20 - o arquivo mais semelhante tem que ter similaridade de no mínimo 0.20. Você pode pensar esse número como 20% de similaridade. Dessa forma, ao analisar um arquivo do CD, se o arquivo com maior similaridade do HD tiver indice maior ou igual a 0.2 ele será selecionado, caso contrário não será reportado nenhum semelhante.

minimofinal=0.15 - se foi encontrtado pelo menos um semelhante com indice maior que o minimo inicial, continua selecionando os semelhantes em índice de semelhança decrescente, desde que seja maior que o minimo final e que respeite o número de semelhanças desejado ("N=3", no caso).

O relatório gerado vai “crescer” ou “diminuir”, de acordo com esses 3 parâmetros.
Se os 2 últimos forem muito altos, pode não encontrar nenhuma semelhança.

8. Executar

Clique em um ponto do código e digite CTRL+Enter

São gerados dois relatórios.

- **gera_html_busca:** para cada arquivo do diretório arqs["busca"]["raiz"], procura semelhantes no diretório arqs["material"]["raiz"], conforme parâmetros especificados.
- **gera_html_material:** para cada arquivo do diretório arqs["material"]["raiz"], procura semelhantes no diretório arqs["busca"]["raiz"], conforme parâmetros especificados.

Os relatórios serão gerados na pasta /home_docker/report_similaridade/relatorios

9. Se não ficou satisfeito e quer reajustar os parâmetros dos relatórios:

Todos os dados de predições, cálculos de similaridade, etc, são guardados em arquivos na pasta do notebook.

Para não ter que refazer toda a leitura de arquivos e cálculos, basta alterar as seguintes variáveis para False (inicialmente estão True):

gera_arqs = False
gera_dados = False

(não esqueça de retornar para True em um novo projeto ou caso os dados sejam alterados)

Volte ao passo 7.

Utilização com GPU

A utilização com GPU pode acelerar a execução em 10x ou mais, utilizando uma placa Nvidia GTX 1080-Ti, por exemplo. Com exceção dos passos 1 ao 3, os demais são idênticos.

Para usar GPU:

- No passo 1 tem que instalar o docker-nvidia (e antes disso pode ser necessário instalar os drives CUDA 9.0 e CUDNN 7.0 da nvidia) em vez do docker.
- Nos passos 2 e 3: usar o comando **docker-nvidia** em vez de docker e a imagem **ufoym/deepo:all-jupyter-py36** em vez de ufoym/deepo:all-jupyter-py36-cpu.

João José de Macedo Neto